Taller 1: Análisis Predictivo y Aprendizaje Estadístico

Caso de Estudio: Advertising Data

Dayanna Alexandra Garzon Linares

Brenda Natalia Rojas Montenegro

Christopher Alexander Vivas Alvarado

FREDY ALEXANDER ORJUELA LOPEZ

Docente

Sistemas Avanzados de Producción

Facultad De Ingeniería

Ingeniería Industrial

Bogotá, 2026

Índice

Introducción **3**

Desarrollo Tecnico **3**

2.1. Fase 1: Estadística Descriptiva y Análisis Exploratorio **3**

2.1.1. Caracterización Numérica 3

2.1.2. Análisis de Distribución y Atípicos 4

2.1.3. Exploración de la Nube de Puntos 7

2.1.4. Evaluación de Asociación 11

2.1.4.1. Interpretación de Resultados 13

2.2. Fase 2: Regresión Lineal y Diagnóstico **14**

2.2.1. Modelamiento Múltiple e Interpretación 14

Interpretación de $\hat{\beta}_1$ (TV = 0.0458) 15

Interpretación de $\hat{\beta}_2$ (Radio = 0.1885) 15

Interpretación de $\hat{\beta}_3$ (Newspaper = -0.0010) 16

2.2.2. Análisis de Bondad de Ajuste 16

2.2.3. Estimación Matricial 18

Conclusión **20**

Introducción

En entornos industriales y comerciales altamente competitivos, la toma de decisiones basada en datos se convierte en un elemento estratégico fundamental. Una de las preguntas más recurrentes en análisis de negocios es determinar el impacto real de la inversión publicitaria sobre las ventas.

El presente documentos analiza el conjunto de datos Advertising, compuesto por 200 mercados distintos, donde se registran inversiones en tres canales publicitarios (TV, Radio y Newspaper) y su correspondiente volumen de ventas. Nuestro punto principal es identificar la existencia de una asociación significativa entre publicidad y ventas, cuantificar la magnitud del efecto de cada medio, evaluar la capacidad predictiva de modelos lineales y no paramétricos y comparar la robustez entre regresión lineal y árboles de decisión.

Desarrollo Tecnico

2.1. Fase 1: Estadística Descriptiva y Análisis Exploratorio

2.1.1. Caracterización Numérica

Las estadísticas descriptivas reales del dataset Advertising son:

Tabla 1. *Medidas de Tendencia Central y Dispersión de Variables Independientes y Variable Dependiente Sales*

Variable	Mean	Media	STD	Min	Max	Skewness	Kurtosis

TV	147.0425	149.75	85.854236	0.7	296.4	-0.069853	-1.226495
Radio	23.2640	22.90	14.846809	0.0	49.6	0.094175	-1.260401
Newspaper	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

2.1.2. Análisis de Distribución y Atípicos

El análisis del coeficiente de asimetría (Skewness) permite evaluar la forma de la distribución de cada variable y determinar si existen concentraciones de datos hacia alguno de los extremos. Para realizar el análisis de nuestros datos tenemos en cuenta:

$$Skewness \approx 0 \rightarrow Distribución\ aproximadamente\ simétrica$$
$$Skewness > 0 \rightarrow Sesgo\ positivo\ (cola\ hacia\ la\ derecha)$$
$$Skewness < 0 \rightarrow Sesgo\ negativo\ (cola\ hacia\ la\ izquierda)$$

Entonces con esto, tenemos en cuenta la regla práctica:

$$|Skew| < 0,5 \rightarrow Aproximadamente\ simétrica$$
$$0,5 \leq |Skew| < 1 \rightarrow Moderadamente\ sesgada$$
$$|Skew| \geq 1 \rightarrow Altamente\ sesgada$$

En nuestro caso, la variable TV, se obtuvo un coeficiente de sesgo de -0.069853, valor muy cercano a cero. Esto indica que la distribución de la inversión en televisión es prácticamente simétrica, con una ligera inclinación hacia la izquierda que resulta estadísticamente irrelevante donde se entiende que la mayoría de los mercados presentan niveles de inversión relativamente equilibrados alrededor de la media.

Ilustración 1. *Histograma y Diagrama de Caja (Box Plot) para Variable TV*

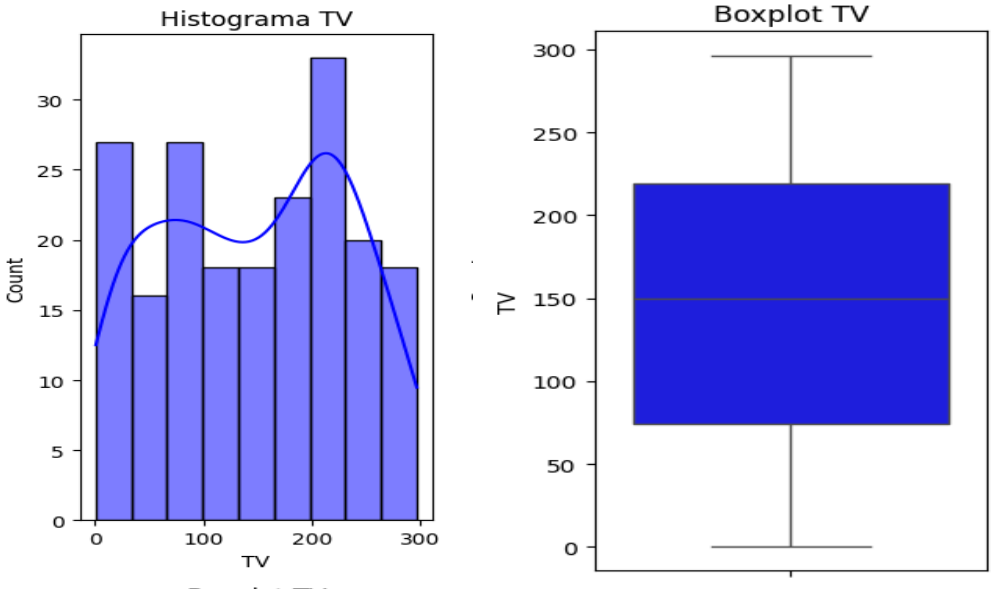

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

La variable Radio presenta un coeficiente de sesgo de 0.094175, también muy cercano a cero, lo que indica una distribución prácticamente simétrica con una ligera asimetría positiva. Esto sugiere que existen algunos mercados con inversiones ligeramente superiores al promedio, pero no en magnitud suficiente.

Ilustración 2. *Histograma y Diagrama de Caja (Box Plot) para Variable Radio*

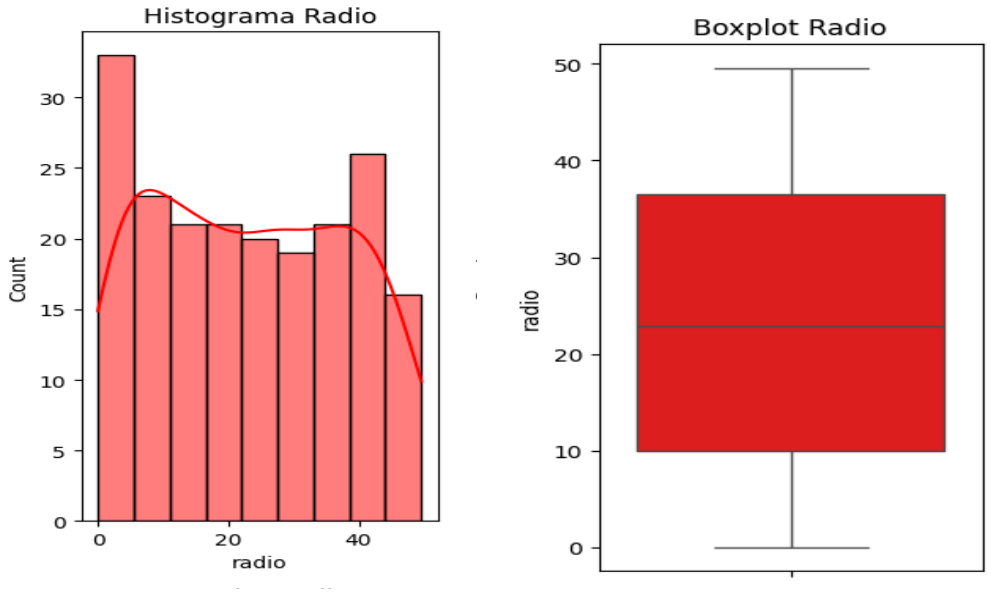

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

La variable Newspaper presenta un coeficiente de sesgo de 0.894720, lo que indica una asimetría positiva moderada. Esto significa que la mayoría de los mercados realizan inversiones relativamente bajas en periódicos, mientras que un grupo reducido concentra inversiones considerablemente más altas.

Ilustración 3. *Histograma y Diagrama de Caja (Box Plot) para Variable Newspaper*

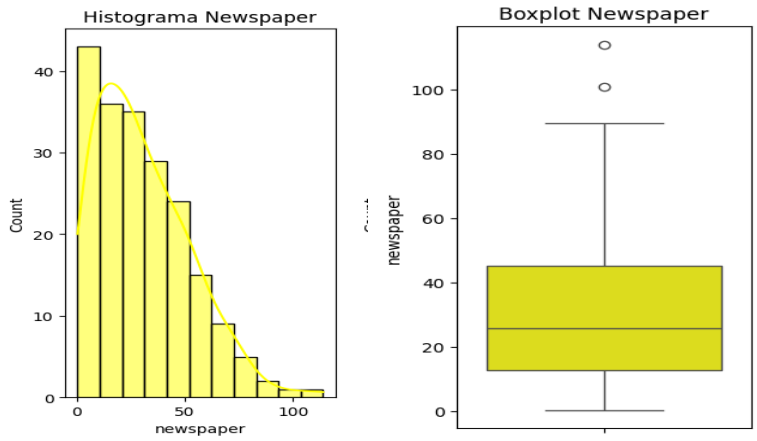

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

La variable Newspaper presenta un coeficiente de sesgo de 0.894720, lo que indica una asimetría positiva moderada. Esto significa que la mayoría de los mercados realizan inversiones relativamente bajas en periódicos, mientras que un grupo reducido concentra inversiones considerablemente más altas

Ilustración 4. *Histograma y Diagrama de Caja (Box Plot) para Variable Sales*

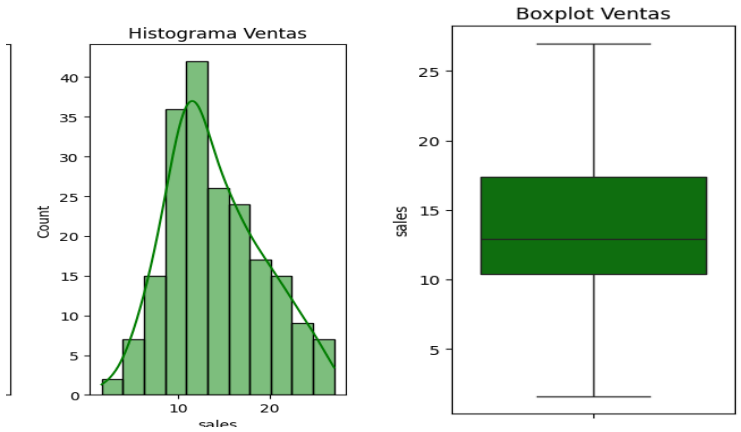

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

¿Se identifican datos atípicos o observaciones que se alejan significativamente de la masa de los datos?

A partir del análisis exploratorio mediante diagramas de caja y la evaluación del sesgo, se identifican posibles valores atípicos principalmente en la variable Newspaper, donde existen inversiones significativamente superiores al resto de la muestra. También pueden observarse algunos valores altos en TV, aunque en menor proporción. Estas observaciones se alejan de la masa principal de los datos y pueden ejercer una influencia desproporcionada en la estimación de los parámetros del modelo lineal.

Lo que indica que si se identifican posibles valores atípicos, especialmente en Newspaper, su influencia no parece ser lo suficientemente fuerte como para invalidar el modelo lineal múltiple, aunque sí justifican un análisis cuidadoso de los residuos y de la estabilidad de los coeficientes estimados.

2.1.3. Exploración de la Nube de Puntos

Con el fin de identificar la naturaleza de la relación entre la variable respuesta (Sales) y cada covariable (TV, Radio y Newspaper), se construyeron diagramas de dispersión (scatter plots) donde el eje horizontal representa la inversión publicitaria y el eje vertical el volumen de ventas.
El análisis visual permite determinar si la relación parece lineal, no lineal, segmentada o si existen observaciones influyentes.

- Sales vs TV

Ilustración 5. *Diagramas de Dispersión (scatter plots) para Variables Sales vs TV.*

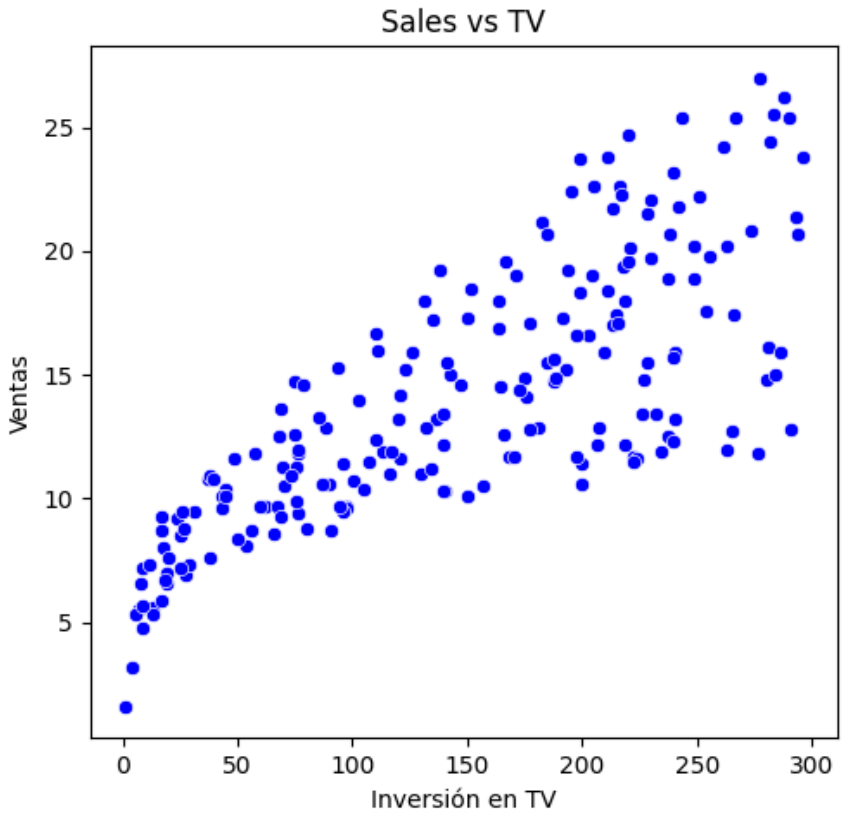

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

El dispersograma entre TV y Sales muestra una clara tendencia creciente aproximadamente lineal. A medida que la inversión en televisión aumenta, las ventas también tienden a incrementarse.

Se observa:

- Una nube de puntos con pendiente positiva.
- Dispersión relativamente homogénea.
- Ausencia de curvaturas pronunciadas.
- No se observan patrones parabólicos.

La relación entre TV y Sales puede modelarse adecuadamente mediante una regresión lineal simple, ya que la estructura de la nube de puntos respalda el supuesto de linealidad.

- Sales vs Radio

Ilustración 6. *Diagramas de Dispersión (scatter plots) para Variables Sales vs Radio.*

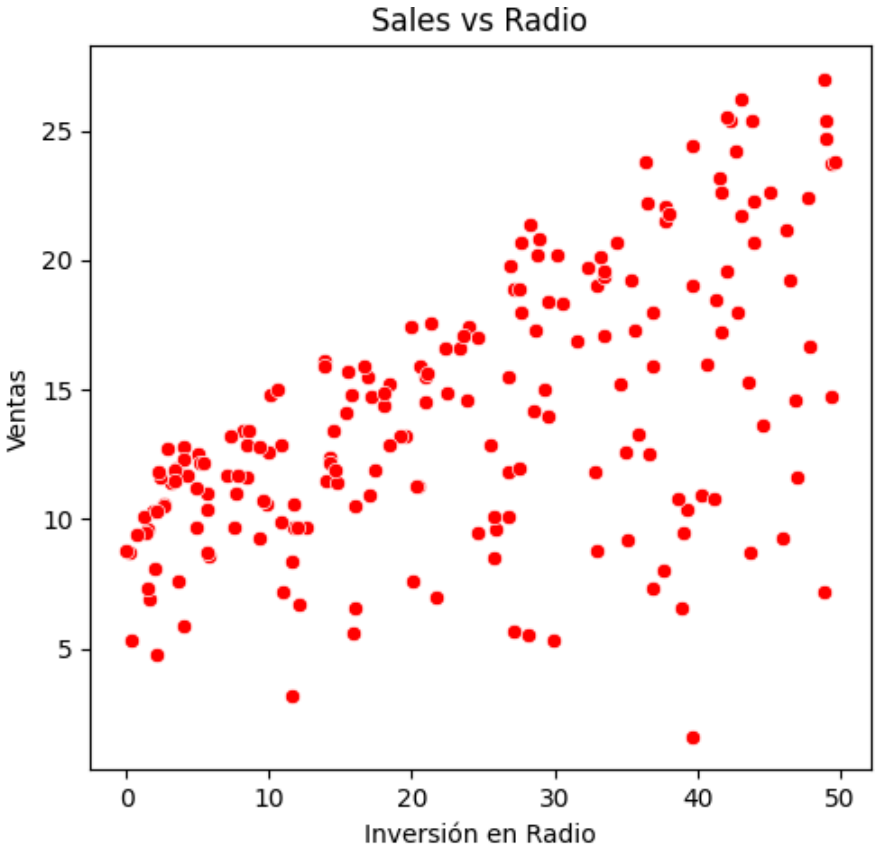

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

El dispersograma entre Radio y Sales también evidencia una relación positiva, aunque con mayor dispersión que en el caso de TV.

Se observa:

- Tendencia creciente clara.
- Mayor variabilidad vertical en niveles intermedios.
- Ausencia de forma parabólica o no lineal.

La relación es compatible con un modelo lineal, aunque ligeramente menos fuerte que la observada con TV. La dispersión sugiere que Radio influye en las ventas, pero no de forma tan dominante como TV.

- Sales vs Newspaper

Ilustración 7. *Diagramas de Dispersión (scatter plots) para Variables Sales vs Newspaper.*

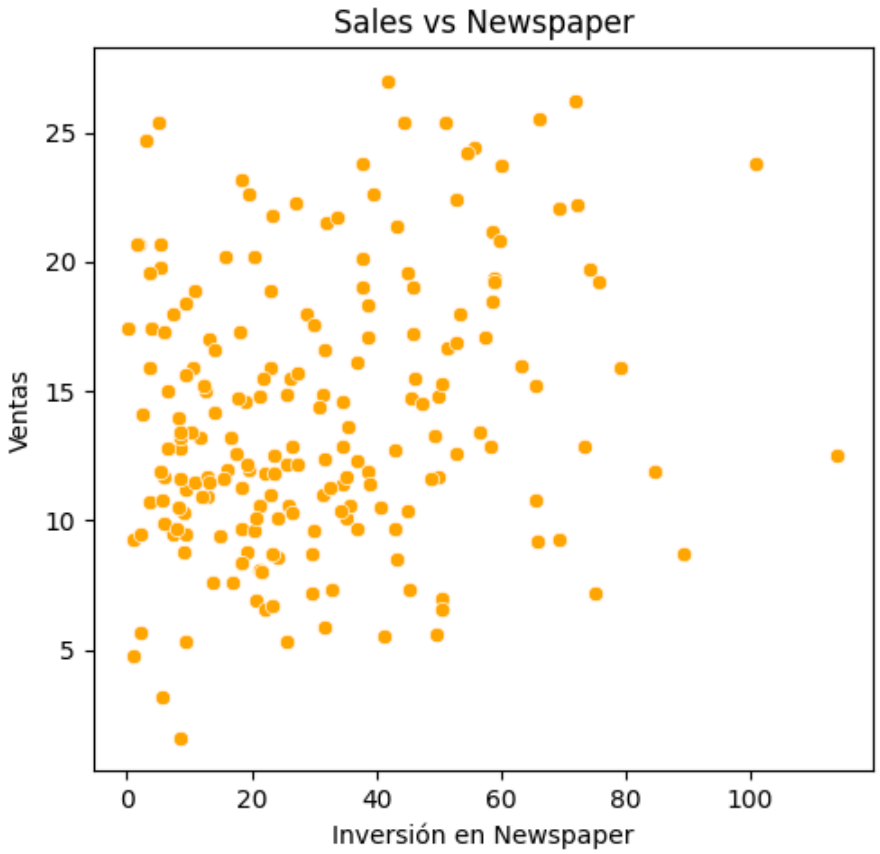

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

El dispersograma entre Newspaper y Sales presenta una estructura diferente:

- Alta dispersión de puntos.
- Ausencia de pendiente claramente definida.
- Concentración de observaciones en niveles bajos de inversión.
- Algunos valores altos aislados.

La relación entre Newspaper y Sales no parece lineal fuerte ni sistemática. Visualmente, no se justifica un modelo lineal simple con esta variable como único predictor.

2.1.4. Evaluación de Asociación

El coeficiente de Pearson mide la fuerza de la relación lineal entre dos variables continuas para nuestro caso podemos identificar la siguiente matriz:

Ilustración 8. *Matrices de Correlación de Pearson para de Variables Independientes y Variable Dependiente Sales.*

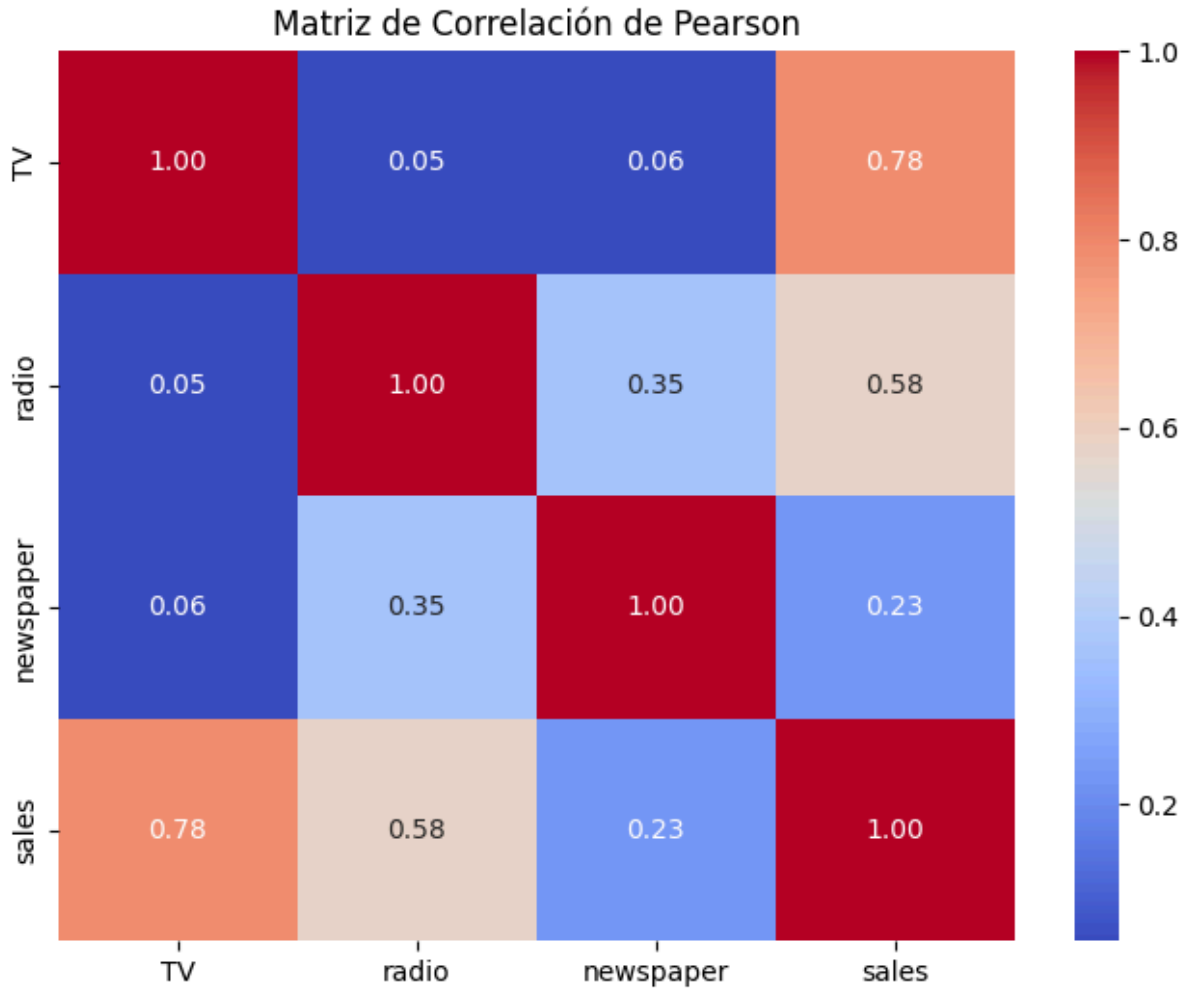

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

- TV – Sales (0.78)

Existe una fuerte asociación lineal positiva. A mayor inversión en televisión, mayores ventas. Este valor cercano a 1 indica que TV es el predictor con mayor relación directa con Sales.

- Radio – Sales (0.58):

Presenta una asociación lineal positiva moderada. Aunque menor que TV, sigue siendo relevante y estadísticamente significativa.

- Newspaper – Sales (0.23):

La relación es débil. Este valor cercano a 0 indica que la inversión en periódicos no explica de manera importante la variabilidad en ventas.

Adicionalmente, se observa que TV y Radio no están altamente correlacionadas entre sí (0.05), lo que reduce problemas de multicolinealidad en el modelo múltiple.

Ilustración 9. *Matrices de Correlación de Spearman para de Variables Independientes y Variable Dependiente Sales.*

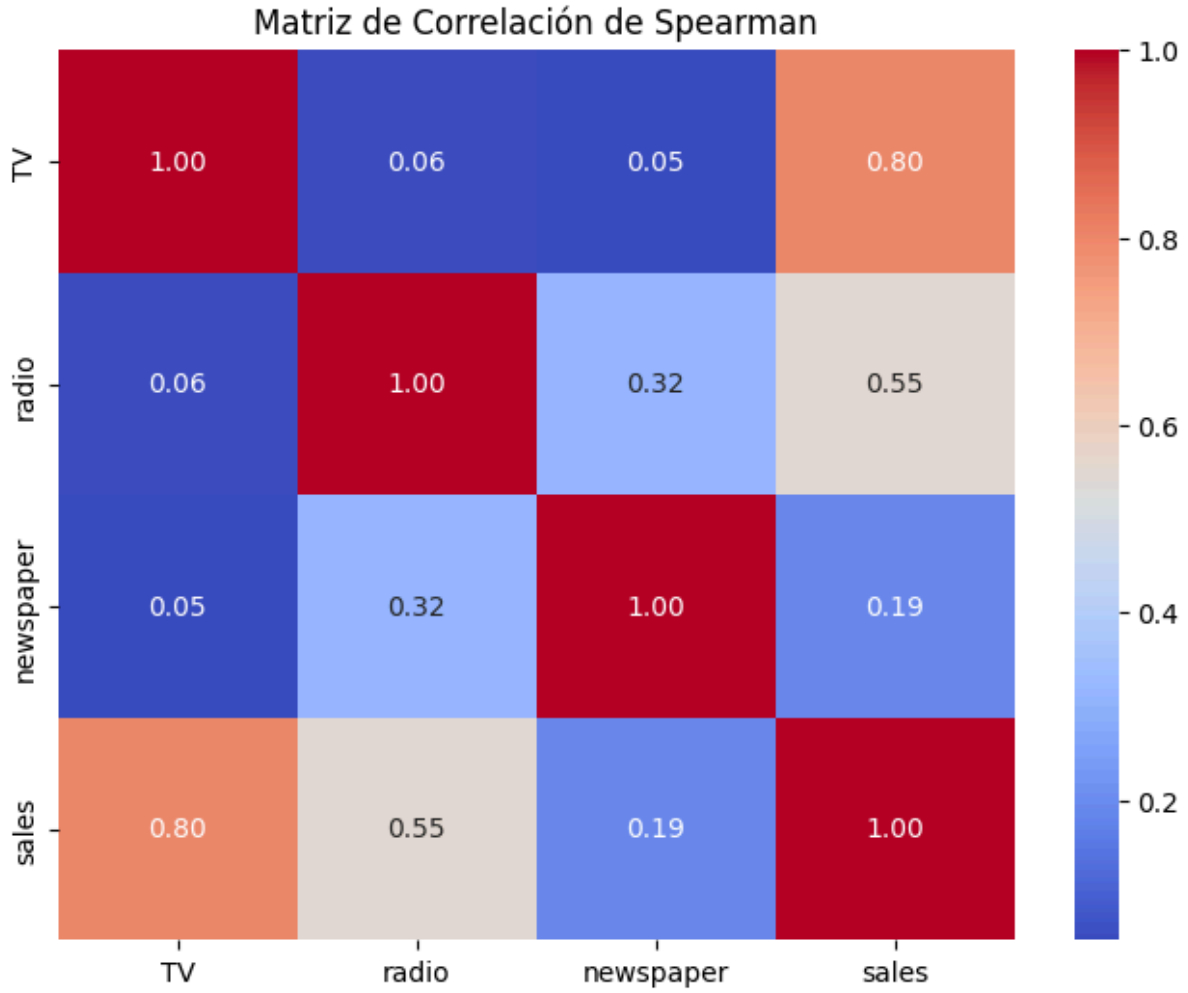

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

La correlación de Spearman evalúa relaciones monótonas, basándose en los rangos de los datos en lugar de los valores originales. Si Spearman hubiera sido considerablemente mayor que Pearson, eso indicaría una relación no lineal pero monótona. No es el caso

Los resultados obtenidos son muy similares a los de Pearson:

- TV – Sales ≈ 0.80
- Radio – Sales ≈ 0.55–0.58
- Newspaper – Sales ≈ 0.20–0.25

El hecho de que los coeficientes de Spearman sean muy similares a los de Pearson indica que:

- La relación entre las variables es esencialmente lineal.
- No existen patrones no lineales fuertes.
- No se identifican relaciones monótonas complejas que no sean lineales.

2.1.4.1. Interpretación de Resultados

- ¿Qué significa un coeficiente cercano a 1 o −1 en el contexto de la inversión publicitaria y el retorno en ventas?

  Un coeficiente cercano a 1 se entiende como una fuerte asociación positiva: cuando la inversión aumenta, las ventas tienden a aumentar proporcionalmente.

  En cambio, un coeficiente cercano a -1 indicaría una relación inversa fuerte, donde un aumento en una variable implicaría disminución en la otra. En este caso no se observan relaciones negativas relevantes.

- ¿Cómo se interpreta un valor de correlación cercano a 0?

  Un valor cercano a 0 se entiende como ausencia de relación lineal significativa. En nuestro caso, Newspaper presenta una correlación baja con Sales, lo que sugiere bajo poder explicativo.

- Compare ambos coeficientes (Pearson y Spearman). ¿Sugieren estos resultados que las relaciones son estrictamente lineales?

Dado que los coeficientes de Pearson y Spearman son muy similares y que la nube de puntos no muestra curvaturas pronunciadas, se concluye que las relaciones son predominantemente lineales.

2.2. Fase 2: Regresión Lineal y Diagnóstico

2.2.1. Modelamiento Múltiple e Interpretación

Se estimó un modelo de regresión lineal múltiple de la siguiente forma:

$$Sales = \beta_0 + \beta_1 TV + \beta_2 Radio + \beta_3 Newspaper \quad (1)$$

dónde Sales representa el volumen de ventas (en miles de unidades), mientras que TV, Radio y Newspaper corresponden a la inversión publicitaria en miles de dólares en cada medio.

La estimación se realizó mediante el método de Mínimos Cuadrados Ordinarios, el cual minimiza la suma de los errores al cuadrado:

$$RSS = \Sigma(y_i - \widehat{y_i})^2 \quad (2)$$

Los resultados obtenidos en Colab fueron los siguientes:

- Intercepto ($\hat{\beta_0}$): 2.9389
- Coeficiente TV ($\hat{\beta_1}$): 0.0458
- Coeficiente Radio ($\hat{\beta_2}$): 0.1885
- Coeficiente Newspaper ($\hat{\beta_3}$): -0.0010

Por lo tanto, la ecuación estimada del modelo es:

$$\widehat{Sales} = 2.9389 + 0.0458TV + 0.1885Radio - 0.0010Newspaper \quad (3)$$

Desde lo matemático, el intercepto se debe ajustar para el plano de regresión. Sin embargo, en la realidad es un poco realista ya que si lo interpretamos sería un mercado sin ningún tipo de herramienta publicitaria. Por otro lado, puede entenderse como la base de ventas atribuible a factores como posicionamiento de marca, distribución o demanda natural del producto.
Por lo tanto, aunque no represente una situación común en la práctica, sí tiene sentido conceptual como punto de referencia del modelo.

Interpretación de $\hat{\beta}_1$ (TV = 0.0458)

El coeficiente $\hat{\beta}_1$ representa la variación esperada en la media de las ventas cuando la inversión en TV aumenta en una unidad como con un precio de $1,000, manteniendo constantes las demás variables.

Esto significa que por cada incremento de $1,000 en inversión en televisión, el promedio de ventas aumenta en 0.0458 miles de unidades, es decir, aproximadamente 45.8 unidades adicionales. Entonces entendemos que hay una relación lineal positiva entre TV y Sales.

Interpretación de $\hat{\beta}_2$ (Radio = 0.1885)

El coeficiente $\hat{\beta}_2$ mide la variación en la media de Sales ante un incremento unitario en Radio, manteniendo constantes TV y Newspaper.

Esto indica que un aumento de $1,000 en inversión en radio incrementa el promedio de ventas en 0.1885 miles de unidades, es decir, aproximadamente 188.5 unidades adicionales. Este es el mayor efecto marginal entre los tres medios.

Interpretación de $\hat{\beta}_3$ (Newspaper = -0.0010)

El coeficiente $\hat{\beta}_3$ mide el cambio esperado en la media de Sales ante un incremento unitario en Newspaper, manteniendo constantes TV y Radio.

Esto implica que un aumento de $1,000 en inversión en periódicos reduciría el promedio de ventas en aproximadamente 1 unidad.

Sin embargo, dado que el valor es extremadamente pequeño y cercano a cero, el efecto práctico es prácticamente nulo. Esto sugiere que Newspaper no contribuye significativamente a explicar la variabilidad en ventas dentro del modelo múltiple.

2.2.2. Análisis de Bondad de Ajuste

Ilustración 10. *Diagrama Regresión Lineal Simple de la Variable TV.*

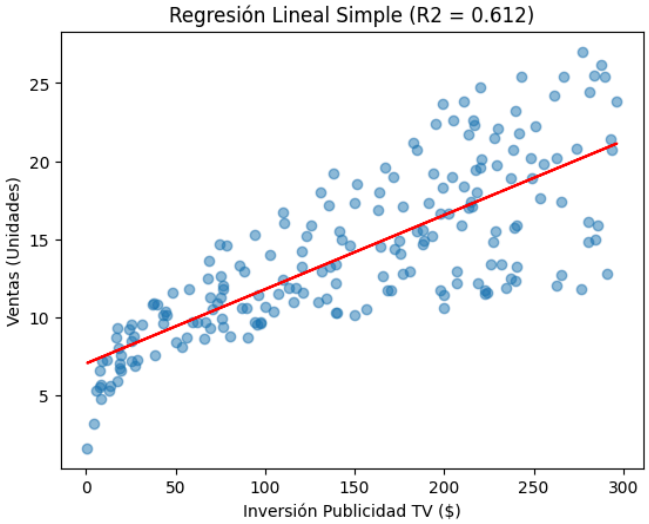

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

Ilustración 11. *Diagrama Regresión Lineal Simple de la Variable TV.*

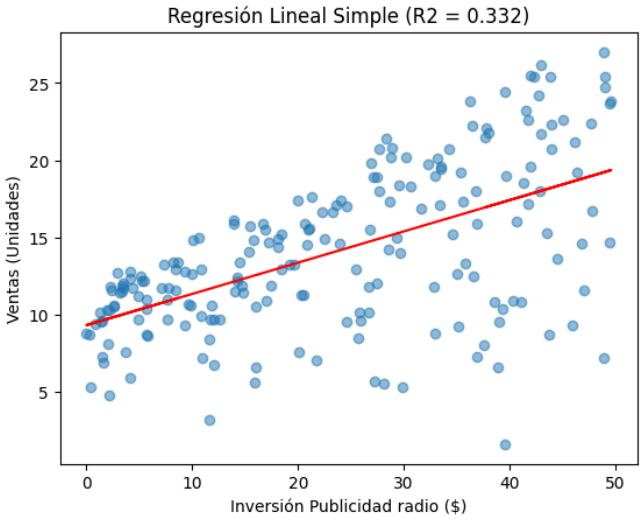

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

Ilustración 12. *Diagrama Regresión Lineal Simple de la Variable TV.*

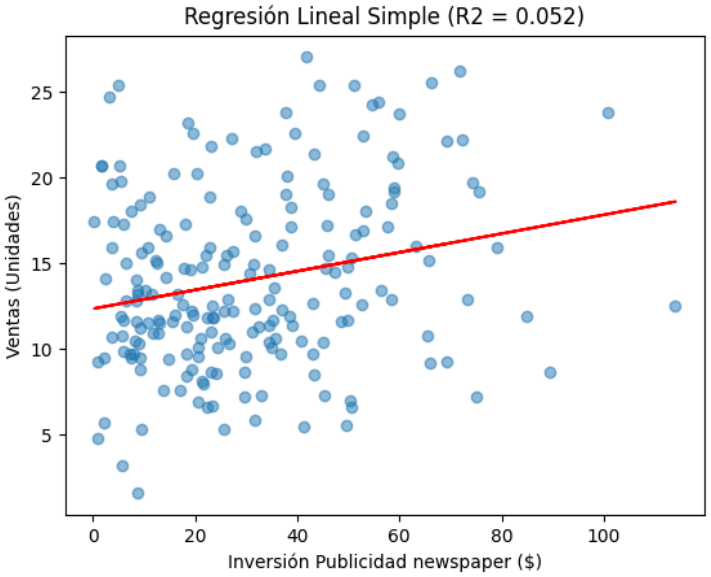

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.}

La inclusión conjunta de Radio y Newspaper incrementa el poder explicativo en aproximadamente 28.5 puntos porcentuales respecto al modelo simple con TV.

Sin embargo, el incremento no se debe principalmente a Newspaper, porque Newspaper individualmente su coeficiente en el modelo múltiple es prácticamente nulo.

El verdadero aumento en el ajuste se debe a la inclusión de Radio, que aporta información adicional no capturada por TV.

Análisis

El modelo simple con TV ya tenía una capacidad alta desde el inicio casi un 90%. Sin embargo, al incorporar Radio, la capacidad predictiva aumenta notablemente.

Esto implica que la estrategia publicitaria no debe basarse únicamente en televisión, sino en una combinación optimizada de medios.

Al contrario el Newspaper no mejora de manera significativa el ajuste del modelo, sigue con un valor menor en comparación a las anteriores variables.

2.2.3. Estimación Matricial

Dadas las matrices de diseño X y el vector de respuesta Y:

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

Tarea:

- Calcule la matriz transpuesta X'.

$$X' = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

- Calcule el producto $X'X$ y su respectiva matriz inversa $(X'X)^{-1}$.

$$X' * X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \cdot \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}$$

$$X' * X = \begin{pmatrix} 1\cdot 1+1\cdot 1+1\cdot 1+1\cdot 1+1\cdot 1 & 1\cdot 1+1\cdot 2+1\cdot 3+1\cdot 4+1\cdot 5 \\ 1\cdot 1+2\cdot 1+3\cdot 1+4\cdot 1+5\cdot 1 & 1\cdot 1+2\cdot 2+3\cdot 3+4\cdot 4+5\cdot 5 \end{pmatrix}$$

$$X' * X = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$$

$$Transpuesta = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}^{-1} \qquad Transpuesta = \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}$$

$$(X'X)^{-1} = \frac{1}{50}\begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \begin{pmatrix} \frac{11}{10} & -\frac{3}{10} \\ -\frac{3}{10} & \frac{1}{10} \end{pmatrix}$$

- Calcule el producto $X'Y$.

$$X' * Y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \cdot \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

$$X' * Y = \begin{pmatrix} 1 \cdot 2 + 1 \cdot 4 + 1 \cdot 6 + 1 \cdot 7 + 1 \cdot 9 \\ 1 \cdot 2 + 2 \cdot 4 + 3 \cdot 6 + 4 \cdot 7 + 5 \cdot 9 \end{pmatrix}$$

$$X' * Y = \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

- Obtenga el vector de parámetros $\hat{\beta}$ y escriba la ecuación de la recta estimada $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$.

$$\widehat{\beta} = (X'X)^{-1} * X' * Y$$

$$\widehat{\beta} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

$$\widehat{\beta} = \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} \begin{pmatrix} 28 \\ 101 \end{pmatrix} = \frac{1}{50} \begin{pmatrix} 25 \\ 85 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} \\ \frac{17}{10} \end{pmatrix}$$

$$\widehat{y} = \frac{1}{2} + \frac{17}{10} x \approx \widehat{y} = 0,5 + 1,7x \approx$$

Conclusión

El desarrollo del trabajo permitió aplicar herramientas de estadística descriptiva y modelamiento predictivo al conjunto de datos Advertising, con el fin de evaluar el impacto de la inversión publicitaria sobre las ventas. El análisis exploratorio evidenció relaciones lineales claras entre TV y Sales, y en menor medida entre Radio y Sales, mientras que Newspaper mostró una asociación débil.

Desde una perspectiva estratégica, los resultados sugieren que la inversión en Radio y TV impacta positivamente el comportamiento de las ventas,

siendo Radio el medio con mayor efecto marginal por unidad invertida. En cambio, la inversión en Newspaper no evidencia un impacto significativo dentro del modelo estimado.